חיזוי גיל מתמונות רשתית באמצעות רשתות נוירונים קונבולוציוניות ושיטות רגולריזציה

דוח פרויקט מסכם

קורס: למידה עמוקה (2026ב'), אוניברסיטת תל אביב | מרצה: ד"ר שי מימון
מגישים: עדי דרור (208009704), שחף ג'ינו (207477639)
קטגוריית הפרויקט: Computer Vision, Healthcare | תאריך הגשה: אוקטובר 2026
מאגר הקוד: github.com/Shahafgino123/retinal-age-cnn

1. מוטיבציה והגדרת הבעיה

הרשתית היא המקום היחיד בגוף שבו מצלמה רגילה יכולה לתעד ישירות כלי דם ורקמת עצב, ללא התערבות פולשנית. לכן, תמונת רשתית בודדת מאפשרת משימת רגרסיה טבעית, חיזוי הגיל הכרונולוגי של המטופל מן התמונה. מעבר לעניין המתודולוגי, ההפרש בין הגיל החזוי לגיל האמיתי, המכונה פער הגיל הרשתי (retinal age gap), הוצע בספרות כסמן ביולוגי. במחקר של Zhu et al. (2023) על 35,913 משתתפים, כל שנת פער ניבאה עלייה של 2% בתמותה מכל סיבה, אף שרווח הסמך של יחס הסיכונים עדיין נוגע ב-1.00.

השאלה שפרויקט זה שואל אינה "האם נשיג את הביצועים הטובים ביותר בעולם". איננו יכולים לעשות זאת, פרויקטי העבר המובילים אומנו על מאות אלפי תמונות ובהעברת למידה ממודלים מאומנים מראש, ולעומת זאת לנו יש 6,902 תמונות אימון ואימון מאפס. השאלה שהנתונים שלנו כן יכולים לענות עליה היא **כיצד החלטות ארכיטקטוניות ורגולריזציה משפיעות על ההכללה כאשר הנתונים מעטים והאימון מתחיל מאפס, וכיצד ניתן להוכיח איזה גורם בדיוק אחראי לכל הפרש**. מסגור זה הוא שקובע את כל מבנה הניסויים: שנים-עשר ניסויים, שכל אחד נבדל בגורם אחד בלבד.

2. סקירת עבודות רלוונטיות

Poplin et al. (2018) הראו לראשונה חיזוי גיל מדויק מתמונת רשתית: MAE של 3.26 שנים על 284,335 מטופלים, עם רשת Inception-v3 מאומנת מראש. הם גם ניתחו מפות קשב: שלושה רופאי עיניים דירגו 100 מפות, וכלי דם הודגשו ב-95% מהן.

Munk et al. (2021) הם הייחוס הרלוונטי באמת עבורנו: MAE של 6.328 שנים (סטיית תקן 5.93) על 135,667 תמונות מ-16,196 מטופלים באוכלוסייה קלינית הטרוגנית, עם רשת ResNet-152 מאומנת מראש. ממוצע הגיל שם, 57.77, כמעט זהה לשלנו (57.4), ולכן זו נקודת ההשוואה ההוגנת – פער של כ-1.3 שנים מול המודל שלנו (7.64 פחות 6.33, כך כתוב גם במצגת), עם פי 20 יותר תמונות ועם התחלה ממודל מאומן מראש.

Zhu et al. (2023) ביססו את מושג פער הגיל הרשתי כסמן תמותה: המודל שלהם השיג MAE של 3.55 שנים, הקוהורטה כללה 35,913 משתתפים ממאגר UK Biobank, ויחס הסיכונים שנמצא הוא 1.02 (רווח סמך 95%: 1.03–1.00). לא נמצא קשר מובהק לתמותה קרדיווסקולרית או סרטנית.

Wang et al. (2024) מוזכרים לעיתים כמי שסותרים את ממצא הקשב של Poplin ושותפיו. מקריאת המאמר זה אינו מדויק: המודל שלהם מנבא **הזדקנות וסקולרית** ולא גיל כרונולוגי, ואינו מדווח MAE כלל. לכן איננו מכריעים את הוויכוח, אלא בודקים אם הדפוס משוחזר במודל קטן שאומן מאפס.

3. תיאור הנתונים

הדאטהסט הציבורי ramankamran/retina-age-analysis, הזמין ב-HuggingFace תחת רישיון MIT, כולל 9,857 תמונות רשתית עם גיל המטופל ועם תוויות קליניות (סוכרת, רטינופתיה סוכרתית, בצקת מקולרית, רטינופתיה יתר-לחץ-דמית, מצב דיסקה/כלי דם/מקולה, דגם מצלמה). התפלגות הגיל בסט האימון: ממוצע 57.4 שנים, סטיית תקן 18.3, טווח 97–5, עם ריכוז כבד בטווח 79–50 (כלל מאגר הנתונים משתרע על טווח רחב יותר של 99–1 שנים). אי-האיזון הזה אינו פרט טכני, הוא ההסבר לממצא המרכזי בסעיף 6.

פיצול	תמונות	מטופלים	תמונות למטופל	תפקיד
train	6,902	3,775	1.83	אימון
validation	1,493	809	1.85	בחירת מודל וכיול
test	1,462	809	1.81	הערכה סופית בלבד

הפיצול הוא ברמת מטופל ולא ברמת תמונה, וזו הבדיקה שכל הפרויקט נשען עליה. ישנן 1.83 תמונות למטופל בממוצע, כלומר כמעט כל מטופל תורם שתי תמונות, אחת לכל עין. פיצול ברמת תמונה היה מכניס את העין השנייה של אותו מטופל לסט האימון ומנפח כל מספר בדוח. הפונקציה check_patient_leakage נקראת בתחילת כל סשן ומעלה חריגה אם מטופל מופיע ביותר מפיצול אחד; החפיפה שנמדדה היא 0 בכל שלושת הזוגות.
בדיקה שנייה- מנבא הממוצע נותן RMSE 18.03 על סט המבחן, שהוא בדיוק סטיית התקן של תוויות המבחן, אימות עצמאי לכך שהפיצול נטען כראוי. שני המספרים חזרו זהים בכל ארבעת הסשנים.

התמונות המקוריות הן כ-1900×1900. פענוח שלהן בכל epoch ארך 600 שניות בזמן שה-GPU ממתין. מטמון חד-פעמי ב-224 פיקסלים הוריד את ה-epoch ל-11 שניות – פי 55. זה ההבדל בין שלושה ניסויים ל-36.

4. המודלים וההיפר-פרמטרים

כל שנים-עשר התצורות הן מופעים של אותה רשת קונבולוציה, שמומשה ב-PyTorch ואומנה מאפס, ללא מודל מאומן מראש. הרשת בנויה מארבעה בלוקי קונבולוציה זהים ומראש רגרסיה קטן. מספר הערוצים מוכפל מבלוק לבלוק, מ-16 בבלוק הראשון ועד 128 ברביעי, ובסך הכול יש לרשת 360,321 פרמטרים. סדר השכבות, מימין לשמאל:

בלוק קונבולוציה – חוזר ארבע פעמים				ראש הרגרסיה			
Conv 3×3	**BatchNorm**	**ReLU**	**MaxPool**	**AvgPool**	**Linear**	**Dropout**	**Linear**
קונבולוציה, ריפוד ששומר על הגודל	נרמול ה batch	אקטיבציה	הקטנה פי 2	מיצוע אדפטיבי לגודל 4×4	128 נוירונים ו-ReLU	בשיעור 0.3, רק בתצורות עם dropout	מוצא יחיד: הגיל החזוי

היפר-פרמטרים קבועים- הערכים הבאים זהים בכל התצורות (פונקציית ההפסד שונה רק ב-loss_l1 וב-loss_hoober):

גודל קלט	Batch size	אופטימייזר	קצב למידה	seeds	פונקציית הפסד
224×224	32	Adam	1e-3	0, 1, 2	MSE

מטריצת הניסויים- כל תצורה נבדלת מעוגן ההשוואה שלה בגורם אחד בלבד, למעט arch_7x7, שבה משתנה גם העומק (ראו סעיף 6). העמודה השמאלית היא תקרת ה-epochs של התצורה:

תצורה	עוגן ההשוואה	הגורם היחיד שמשתנה	epochs
cnn_plain	ridge_linear	רשת קונבולוציה במקום מודל לינארי, בלי רגולריזציה	15
cnn_dropout	cnn_plain	הוספת dropout בשיעור 0.3 בראש הרשת	15
cnn_wd	cnn_plain	הוספת weight decay בגודל 1e-4	15
cnn_es	cnn_plain	הוספת early stopping עם סבלנות של 5 epochs	15
cnn_all	cnn_plain	שלושת הרגולריזטורים יחד	20
cnn_aug	cnn_all	אוגמנטציה קלה: סיבוב, היפוך אופקי ושינוי בהירות	20
cnn_aug_long	cnn_aug	תקרת epochs גבוהה יותר	40
arch_7x7	cnn_all	פילטר 7×7 בשלושה בלוקים במקום 3×3 בארבעה, ברוחב ערוצים מכויל לאותו מספר פרמטרים	20
arch_valid	cnn_all	ריפוד valid במקום same	20
arch_drop_early	cnn_all	העברת ה-dropout מראש הרשת אל בין בלוקי הקונבולוציה	20
loss_l1	cnn_all	פונקציית הפסד L1 במקום MSE	20
loss_huber	cnn_all	פונקציית הפסד Huber עם δ=5 שנים במקום MSE	20

שלוש החלטות מתודולוגיות הן שהופכות את הטבלה לתכנון ניסויי:

- **ניטרול מספר הפרמטרים-** בגרסה הראשונה היו לתצורת ה-7×7 פי 1.98 פרמטרים מהבקרה, ולתצורת הריפוד valid היו 26% פחות, כך שבפועל מדדנו קיבולת ולא ארכיטקטורה. שכבת המיצוע האדפטיבי מנטרלת את השפעת הריפוד לחלוטין: לתצורה arch_valid יש בדיוק 360,321 פרמטרים, כמו לבקרה. ברשת ה-7×7 כיילנו את רוחב הערוצים בחיפוש בינארי עד 359,446 פרמטרים, סטייה של פחות מ-0.25% מהבקרה.
- **בקרת אקראיות-** ה-seed נקבע לפני בניית המודל. בגרסה קודמת הוא נקבע אחריה, כך שכל ניסוי התחיל מאתחול משקולות שונה, וחלק מכל הפרש שנמדד היה רעש אתחול. סדר ערבוב הנתונים נקבע במחולל אקראיות ייעודי, כדי שיהיה זהה בין התצורות, ותהליכי הטעינה של ה-DataLoader מקבלים seed משלהם, כדי שגם האוגמנטציה תהיה משוחזרת. כל תצורה רצה עם שלושה seeds שונים ומדווחת כממוצע ± סטיית תקן.
- **בחירת המשקולות כגורם מוצהר-** תצורה בלי early stopping מוערכת לפי המשקולות של ה-epoch האחרון, ותצורה עם early stopping מוערכת לפי המשקולות הטובות ביותר על סט האימות. ההבדל הזה הוא חלק מה-early stopping עצמו, ולכן הוא מופיע במטריצה כגורם מוצהר ואינו משתנה אקראית בין תצורות.

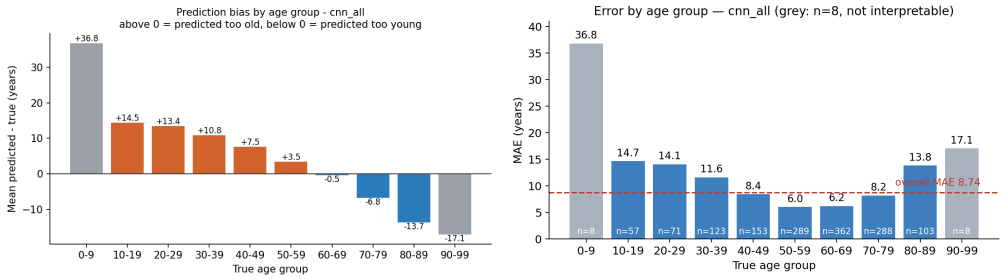
5. הצגת התוצאות

כל המספרים על סט המבחן. סט המבחן לא שימש כעוגן לשום החלטה. בחירת המשקולות, עצירה מוקדמת והכיול נעשו על סט האימות בלבד, והוא חושב פעם אחת בסוף כל הרצה. ממוצע שלושת ה-seeds. עמודת sd היא סטיית התקן המדגמית בין שלושת ה-seeds. השורה הראשונה היא הרף שכל מודל חייב לעבור.

תצורה	MAE	sd	RMSE	R^2	פרמטרים
מנבא הממוצע (57.4)	14.316	–	18.025	0.000	–
ridge על מאפיינים ידניים	9.553	–	12.645	0.508	–
cnn_aug	**7.638**	0.132	10.161	0.682	360,321
cnn_wd	7.655	0.157	10.154	0.683	360,321
loss_huber	7.722	0.270	10.416	0.666	360,321
arch_valid	7.888	0.539	10.511	0.659	360,321

תצורה	MAE	sd	RMSE	R^2	פרמטרים
cnn_es	7.970	0.305	10.587	0.655	360,321
arch_7x7	8.018	0.079	10.632	0.652	359,446
cnn_aug_long	8.032	0.733	10.651	0.649	360,321
loss_l1	8.109	0.142	10.847	0.638	360,321
cnn_plain	8.129	0.490	10.664	0.649	360,321
cnn_dropout	8.600	0.606	11.187	0.614	360,321
cnn_all	8.672	0.085	11.457	0.596	360,321
arch_drop_early	9.051	0.103	12.056	0.553	360,321

כל שתים-עשרה התצורות משיגות MAE נמוך משל שני הבייסליינים. את עמודת ה sd יש לקרוא לפני הדירוג: ההרצות אינן דטרמיניסטיות על GPU (סעיף 7), ולכן פער קטן מחצי שנה ב MAE משקף רעש (רף גס) ולא הבדל אמיתי. מכאן שההפרש בין cnn_aug ל cnn_wd אינו בר-פרשנות, ושש התצורות הראשונות שקולות למעשה. הפערים הגדולים (כל CNN מול הבייסליינים) חורגים מסף זה בשיעור ניכר, ולפיכך ניתנים לפרשנות.



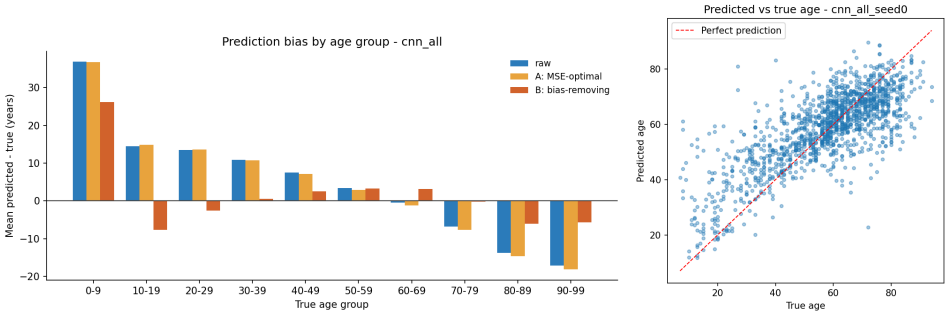
איור 1 (ימין): MAE לפי קבוצת גיל, cnn_all seed 0. השגיאה מזערית בגילי 50–69 וגדלה לשני הכיוונים. הקו המקווקו הוא השגיאה הכוללת, 8.74 שנים. שתי העמודות האפורות נשענות על 8 תמונות כל אחת ואינן ניתנות לפרשנות לפרשנות.
איור 2 (שמאל): כיוון השגיאה באותן קבוצות. חיובי פירושו שהמודל ניבא מבוגר מדי ושלילי צעיר מדי. הערך חוצה את האפס ב-60–69, בסמוך לגיל הממוצע באימון.

6. ניתוח תוצאות

רגולריזציה אינה מצטברת- מול העוגן cnn_plain, שהשיג MAE של 8.129, הוספת weight decay מורידה את השגיאה ב-0.47 שנים, הוספת early stopping משפרת ב-0.16 בלבד, ואילו הוספת dropout מעלה אותה ב-0.47, ושלושתם יחד מרעים ב-0.54. כלומר, התוצאה גרועה ב-0.71 שנים ממה שהיה מתקבל לו האפקטים היו מצטברים (7.97 צפוי מול 8.672 בפועל- אמנם תקרת ה-epochs של cnn_all גבוהה יותר (20 מול 15), אך ה-early stopping עצר את שלושת ה-seeds ב-10-14 epochs, כך שהתקרה לא השפיעה) וגרועה ב-1.02 שנים מהרגולריזטור הבודד הטוב ביותר, weight decay. עם 360 אלף פרמטרים ו-6,902 תמונות אימון, המודל אינו נמצא במצב שבו הצטברות רגולריזציה משתלמת.במקביל, סטיית התקן בין ה-seeds מתכווצת מ-0.49 בתצורה cnn_plain , ל-0.085 בתצורה cnn_all , כלומר המודל נעשה יציב יותר ושגוי יותר בעת ובעונה אחת – זהו ה-bias–variance tradeoff, הנצפה ישירות בפיזור ה-seeds. אותה מסקנה עולה גם כשהעוגן הוא cnn_all עצמו: שש תצורות נבחנות מולו, כל אחת בשינוי של גורם אחד, ובחמש מהן השגיאה נמוכה יותר - אוגמנטציה ב-1.03 שנים ופונקציית Huber ב-0.95 . Huber עדיפה גם על L1 (7.72 מול 8.11), אף שפונקציית L1 זהה במבנה למטריקה המדווחת עצמה, משום שגרדיאנט שגודלו קבוע מקשה על התכנסות עדינה.

שגיאה ממוצעת אחת מסתירה שני משטרים- שלושה מארבעת הניתוחים שלהלן הורצו כולם על תצורה אחת - cnn_all עם seed 0, שה-MAE שלה 8.74 – משום שרק עבורה נשמרו החיזויים המלאים על סט המבחן. הפירוק לפי קבוצות גיל מראה שגיאה בצורת U (איור 1): מינימום של 6.04 שנים בקבוצה 50–59, מול 13.85 בקבוצה 80–89. ההטיה יורדת באופן מונוטוני (איור 2), מהערכת יתר של 14.5 שנים בגילי 10–19 ועד הערכת חסר של 13.7 שנים בגילי 80–89, וחוצה את האפס בקבוצה 60–69, בסמוך לממוצע האימון (57.4). זוהי נסיגה לממוצע (regression to the mean): מודל שממזער שגיאה ריבועית מול התפלגות גיל לא מאוזנת לומד להיטות למרכז ההתפלגות. לכן דיווח של 8.74 כמספר יחיד מטעה – המודל סביר בגיל העמידה וכמעט חסר תועלת בקצוות. (הקבוצות 0–9 ו-90–99 מכילות 8 תמונות כל אחת ואינן ניתנות לפרשנות, הן מדווחות לשקיפות בלבד)

הדחיסה אינה באג- על סט האימות מתקיים הקשר $\text{pred} = 0.569 \times \text{true} + c$, כלומר המודל פורש רק 57% מטווח הגילאים. בחנו שני תיקונים אפיניים מהצורה: $\mathbf{a} \times \mathbf{pred} + \mathbf{b} = \mathbf{גיל_מתוקן}$, שניהם מותאמים על סט האימות בלבד. **תיקון A** בוחר את a כך שימזער שגיאה ריבועית, מתאים מקדם של 0.967 (קרוב לזהות) ולכן כמעט אינו משנה את החיזויים, וה MAE זז מ-8.738 ל-8.748 בלבד. זו עדות לכך שהחיזויים הגולמיים כבר היו אופטימליים: הנטייה למרכז היא ההתנהגות הנכונה תחת פונקציית ההפסד שבה המודל אומן. **תיקון B** הופך את הדחיסה שלמעלה ישירות ($a = 1/0.569$) ומותח את החיזויים בחזרה אל קו הזהות. התלות בגיל יורדת ממתאם שלילי של 0.677 למתאם זניח של 0.012, ומחירו 2.8 שנות MAE - עלייה של 32%. כיול איזוטוני משפר ב-0.11 שנים בלבד, כלומר לא נותר מבנה לא-לינארי של ממש שניתן לנצלו. המשמעות המעשית: חיזוי גולמי כשהמטרה היא דיוק, ותיקון B כשהפער עצמו הוא מושא המחקר.

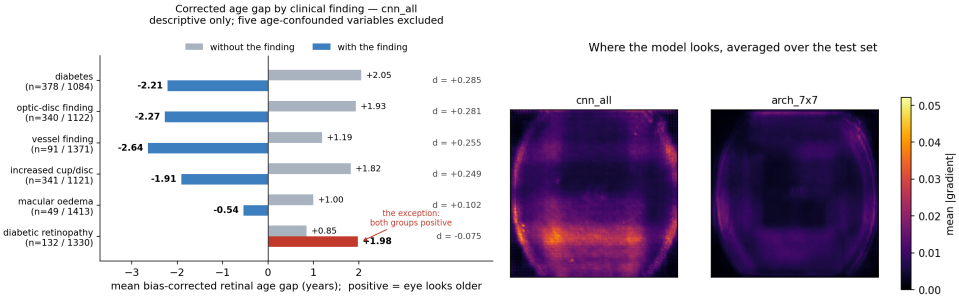


איור 3 (ימין): הגיל החזוי מול האמיתי, נקודה לכל תמונת מבחן. הענן שטוח מהאלכסון, וזו הדחיסה שהשיפוע 0.569 מכמת.
איור 4 (שמאל): ההטיה לפי קבוצת גיל לפני הכיול ואחריו. תיקון A כמעט אינו משנה דבר, תיקון B מיישר אותה סביב האפס, במחיר 2.8 שנות MAE.

לאן המודל מסתכל- חישבנו מפות saliency מבוססות גרדיאנט על 256 תמונות. במודל עם פילטר 7×7 עוצמת הקשב במרכז התמונה גדולה פי 2.24 מזו שבקצה, לעומת פי 1.32 במודל עם פילטר 3×3 (איור 5), והמפה שלו גם פחות חדה: ב-10% הפיקסלים העליונים מרוכזת 0.187 מהמסה, מול 0.218 במודל 3×3. זה בדיוק מה שצפוי מ־receptive field גדול יותר. את היחס יש לקרוא בזהירות: הוא משווה את רבע הרדיוס הפנימי לרבע החיצוני, והטבעת החיצונית היא ברובה הרקע השחור שמחוץ לשדה הראייה. כמו כן, תצורת ה-7×7 שונה מהבקרה גם בעומק (שלושה בלוקים במקום ארבעה), ולכן ההשוואה היא בין שני שדות קליטה ולא בין גודלי פילטר בלבד. המתאם בין שתי מפות הקשב הממוצעות הוא 0.411: גבוה דיו כדי לומר שהשניים מסתכלים על אזורים דומים, ונמוך דיו כדי לומר שאינם שקולים, וזו בדיוק ההנחה שעליה נשענת השוואת ה-7×7 מול ה-3×3. את ממצא כלי הדם של Poplin ושותפיו לא הצלחנו לשחזר. המתאם בין מפות הקשב לקונטרסט מקומי, פרוקסי גס לכלי דם, הוא 0.16–0.13 בשני המודלים. הניסוח הכשר אינו "הם טעו", אלא שעם פרוקסי גס ומודל קטן שאומן מאפס אין לנו בסיס לטענה לשום כיוון.

פער הגיל מול התוויות הקליניות (כיוון הפוך מהספרות)- בעזרת הפער המתוקן (תיקון B, שהתלות שלו בגיל היא 0.012 בלבד) השווינו, עבור כל תווית, בין המטופלים שהממצא נמצא אצלם לאלה שלא. בחמישה משתנים הגיל עצמו מבלבל את ההשוואה (הפרש של יותר מחמש שנים בגיל הממוצע בין הקבוצות) ולכן אינם מדווחים כלל, נותרו שישה ממצאים קליניים (איור 6). גודלי האפקט הגדולים ביותר נמצאו בסוכרת (d=0.285; פער ממוצע של 2.05 שנים בקרב מי שאין לו סוכרת, מול פער שלילי של 2.21 שנים בקרב מי שיש לו), בממצא בדיסקה האופטית (d=0.281), בממצא בכלי הדם (d=0.255) וביחס cup/disc מוגדל (d=0.249).

בארבעת אלה הכיוון הפוך: המטופלים עם הממצא מקבלים פער שלילי, כלומר המודל מעריך את גילם כנמוך מגילם בפועל, בעוד הספרות מצפה שמחלה תלווה במראה רשתית מבוגר יותר. הדפוס חוזר בארבעה מתוך ששת הממצאים שנותרו, בבצקת מקולרית הכיוון זהה אך העוצמה זניחה (d=0.102, על 49 מטופלים בלבד). היוצאת מן הכלל היא רטינופתיה סוכרתית, שבה הכיוון מתהפך: פער חיובי של 1.98 שנים בקרב הנבדקים עם הממצא, מול 0.85 בקרב מי שאין לו (d=−0.075). הפער חיובי בשתי הקבוצות ובכיוון שהרפואה מצפה לו, ולכן אינה משתלבת בדפוס. בארבעת הממצאים הגדולים ההיפוך עקבי ואינו מוסבר בגיל. ההסבר הפשוט ביותר הוא שהתוויות הללו משקפות את אופן הכניסה של המטופל לדאטהסט (מסלול הפניה, תוכנית סקירה, ציוד הצילום) ולא ביולוגיה של הרשתית. בהתאם, אנו מדווחים על אסוציאציה שנצפתה, בגודל ובכיוון שצוינו, ולא על סיבתיות. לא הורצו מבחני מובהקות, ובגודל המדגם שלנו אין להם כוח סטטיסטי של ממש: כדי לזהות יחס סיכונים בסדר גודל של 1.02 נדרשו במחקר של Zhu ושותפיו 35,913 משתתפים, ולנו 1,462 תמונות מבחן בלבד.



איור 5 (ימין): מפות ה-saliency הממוצעות על 256 תמונות מבחן; בהיר פירושו השפעה גדולה יותר. מפת ה-7×7 חלקה ופחות מרוכזת מזו של 3×3, והמתאם בינהן 0.411.
איור 6 (שמאל): הפער המתוקן לפי ממצא קליני, אפור לקבוצה בלי הממצא וצבע לקבוצה איתו. בארבעת הממצאים העליונים הקבוצה עם הממצא נראית צעירה יותר; רטינופתיה סוכרתית יוצאת דופן.

7. דיון: תובנות, מגבלות וכיווני המשך

התובנה המרכזית היא מתודולוגית: בתנאי נתונים דלים מנגנוני הרגולריזציה מצמצמים את הפיזור בין ההרצות אך מגדילים את השגיאה, ומסקנה כזו ניתנת להסקה רק כאשר כל ניסוי משנה גורם אחד ויש רף רעש מוצהר. בנוסף, אותרו תשע תקלות מתודולוגיות בעבודה עצמה: קביעת ה-seed אחרי בניית המודל, שלוש תצורות זהות ברמת הבייט, פי 1.98 פרמטרים בתצורת ה-7×7, פונקציית Huber שהתנהגה כמו L1 בגלל ערך ברירת המחדל δ=1, בחירת

משקולות לא אחידה, אקראיות לא מוזרעת בתהליכי טעינת הנתונים, היפוך סימן בניתוח הביומרקר, בייסליין ברזולוציה מלאה, ואי-דטרמיניזם של cuDNN. כל אחת מהן הייתה מובילה למסקנה שגויה ומשכנעת. שמונה תוקנו, והאחרונה מדווחת כמגבלה. פירוט מלא בקובץ docs/RESULTS.md.

מגבלות:

- אין שחזור ביט-לביט על GPU. ההגדרה cudnn.benchmark = True בוחרת אלגוריתמי קונבולוציה לפי מדידת זמנים, כך ששתי הרצות עם אותו seed עלולות להתפצל. מדדנו זאת: התצורה cnn_aug עם seed 1 הגיעה ל-MAE של 7.62 אחרי 20 epochs, בעוד התצורה cnn_aug_long עם אותו seed (אותה תצורה עם תקרת epochs גבוהה יותר) נעצרה כבר ב-epoch התשיעי עם 8.87. ומסטיית התקן רף הרעש שהתקבל הינו כחצי שנה.
- דאטהסט יחיד ממקור אחד, בלי אימות חיצוני על אוכלוסייה או מצלמה אחרת.
- 6,902 תמונות אימון – פי 20 עד 40 פחות מהעבודות שאנו משווים אליהן, ואימון מאפס בלי העברת למידה, שהיא בחירה מכוונת התואמת את שאלת המחקר אך מגבילה את הביצועים המוחלטים.
- שלושה seeds ולא חמישה – פשרה מודעת מול מגבלת ה-GPU החינמי.
- שכבות BatchNorm נמצאות בשימוש על אף שלא נלמדו בקורס.
- הניתוח הקליני תיאורי בלבד: גדלי קבוצות, ממוצעים וגדלי אפקט, בלי מובהקות ובלי סיבתיות.

כיווני המשך, לפי סדר התועלת הצפויה:
(1) התחלה ממודל מאומן מראש – השינוי שיבדיל בין "מעט נתונים" ל"שיטה חלשה", והיחיד שוויתרנו עליו מדעת. (2) כיבוי ההגדרה cudnn.benchmark והרצה חוזרת של שש התצורות הראשונות, רק אז הדירוג ביניהן יהפוך למשמעותי. (3) טיפול בנטייה למרכז כבר באימון ולא בדיעבד – איזון קבוצות הגיל או מתן משקל גבוה יותר לגילאים נדירים בפונקציית ההפסד. (4) מדידה מפורשת של כלי הדם באמצעות סגמנטציה במקום פרוקסי הקונטרסט, כדי לסגור את שאלת הקשב. (5) אימות על אוכלוסייה שנייה.

8. רשימת מקורות

1. Poplin R, Varadarajan AV, Blumer K, et al. Prediction of cardiovascular risk factors from retinal fundus photographs via deep learning. *Nature Biomedical Engineering* 2018; 2: 158–164.
2. Munk MR, Kurmann T, Márquez-Neila P, et al. Assessment of patient specific information in the wild on fundus photography and optical coherence tomography. *Scientific Reports* 2021; 11: 8621.
3. Zhu Z, Shi D, Peng G, et al. Retinal age gap as a predictive biomarker for mortality risk. *British Journal of Ophthalmology* 2023; 107(4): 547–554.
4. Wang R, Tan Y, Zhong Z, et al. Deep learning-based vascular aging prediction from retinal fundus images. *Translational Vision Science & Technology* 2024; 13(7): 10.

9. תרומת חברי הצוות

שחף ג'ינו –הקוד (התיקייה src), תכנון מטריצת הניסויים ומנגנוני ההוגנות (ניטרול פרמטרים, בקרת אקראיות), הרצת 36 המודלים ב-Kaggle, ארבעת הניתוחים שלאחר האימון (שגיאה לפי גיל, כיול, מפות saliency וביומרקר), איתור ותיקון תשע התקלות המתודולוגיות, והתיעוד בקבצים docs/RESULTS.md ו-README.md.
עדי דרור –תכנון גישות הפתרון, סקירת הספרות ואימות המקורות, כתיבת הדוח וניסוח הפרשנות, ובניית הפרזנטציה.

10. קישור למאגר הקוד והוראות שחזור

https://github.com/Shahafgino123/retinal-age-cnn

המאגר מכיל את הקוד (התיקייה src), שתי מחברות ההרצה, את כל התוצאות – 36 קובצי checkpoint, קובץ JSON לכל הרצה ו-85 איורים, ואת התיעוד. כל ההרצות בוצעו על כרטיס T4 החינמי של Kaggle, בזמן GPU כולל של כ-3.5 שעות. **השחזור** נעשה בשלושה שלבים:

- **הכנת הנתונים-** הרצה חד-פעמית, עם חיבור לאינטרנט, של המחברת kaggle_01_prepare_data.ipynb מהתיקייה notebooks. המחברת מורידה את הדאטהסט ובונה את התיקייה images_224 ואת קובצי החלוקה.
- **העלאת הקוד-** פרסום התיקייה src כדאטהסט ב-Kaggle בשם Retina-code.
- **הרצת הניסויים-** הרצת המחברת kaggle_02_run_all_experiments.ipynb כששני הדאטהסטים מצורפים. הפונקציה train_cnn מדלגת על כל הרצה שקובץ המדדים שלה כבר קיים, ולכן אפשר להריץ את המחברת שוב ולהמשיך גם אחרי ניתוק.

להרצה מקומית יש להתקין את הספריות שבקובץ requirements.txt; אותו קוד רץ גם על CPU או על MPS, לאט יותר. לפני כל ששן רצות שתי בדיקות חוסמות: הפונקציה check_patient_leakage מוודאת שאין חפיפת מטופלים בין שלושת הפיצולים, והפונקציה run_mean_predictor מוודאת שה-RMSE של מנבא הממוצע הוא 18.03, כמו סטיית התקן של תוויות המבחן. הרכיב היחיד שאינו ניתן לשחזור ביט-לביט הוא בחירת אלגוריתמי הקונבולוציה של cuDNN (סעיף 7). פירוט נוסף בקבצים README.md ו-docs/RESULTS.md. זהו פרויקט קורס שאינו מיועד לשימוש קליני; הדאטה סט משמש בהתאם לתנאי הרישיון שלו.