למידה עמוקה 2026ב' · אוניברסיטת תל אביב · פרויקט גמר

חיזוי גיל מתמונות רשתית

רשת קונבולוציה קטנה שאומנה מאפס, וניתוח של מה שלמדה בפועל

9,857 תמונות רשתית

360,321 פרמטרים, ללא אימון מראש

36 הרצות · כ-3.5 שעות GPU

שחף ג'ינו ועדי דרור

רקע ושאלת המחקר

האם אפשר להעריך את גיל האדם מצילום אחד של העין?

הקלט: צילום רשתית

צילום קרקעית העין: כלי דם ורקמת עצב, בלי פעולה פולשנית.

הפלט: גיל המטופל

מספר בשנים. הגיל האמיתי ידוע לכל תמונה, ולכן זו בעיית רגרסיה.

למה זה מעניין

פער גיל רשתי = גיל חזוי פחות גיל אמיתי. נמצא קשור, במידה קטנה, לסיכון מוגבר לתמותה.

שאלת המחקר

העבודות המובילות: מאות אלפי תמונות ומודל מאומן מראש. אצלנו: 6,902 תמונות ואימון מאפס. לכן השאלה אינה ביצועי שיא, אלא: **אילו החלטות ארכיטקטורה ורגולריזציה משפיעות על ההכללה כשיש מעט נתונים, וכיצד לבודד את ההשפעה של כל אחת.**

איך נראה הקלט

ארבע תמונות מסט המבחן, בגודל 224×224 כפי שהרשת רואה אותן. החיזויים של cnn_all (seed 0).



גיל אמיתי **18**
חיזוי **26** (+8)



גיל אמיתי **23**
חיזוי **36** (+13)



גיל אמיתי **51**
חיזוי **64** (+13)



גיל אמיתי **68**
חיזוי **58** (-10)

רואים כלי דם, דיסקה אופטית ומקולה, אבל גם הבדלי צבע ותאורה בין מצלמות.
הצעירים קיבלו חיזוי מבוגר מדי והמבוגר חיזוי צעיר מדי: דפוס שנחזור אליו בממצא 2.

עבודות קודמות

נקודות ייחוס לתוצאה שלנו, לפי היקף הנתונים והשיטה.

מחקר	משימה	תוצאה עיקרית	נתונים ושיטה
Poplin et al., 2018 Nature Biomed. Eng.	חיזוי גיל וגורמי סיכון קרדיווסקולריים	טעות ממוצעת של **3.26** שנים	284,335 מטופלים, Inception-v3 מאומן מראש
Munk et al., 2021 Scientific Reports	חיזוי גיל באוכלוסייה קלינית	טעות ממוצעת של **6.33** שנים	135,667 תמונות, ResNet-152 מאומן מראש
Zhu et al., 2023 Br. J. Ophthalmology	פער הגיל הרשתי כמנבא תמותה	כל שנת פער: סיכון תמותה גבוה ב-**2%**	35,913 משתתפים, UK Biobank
Wang et al., 2024 Transl. Vis. Sci. Technol.	הזדקנות וסקולרית, לא גיל כרונולוגי	לא מדווחת טעות בשנים	8,865 תמונות

MAE טעות ממוצעת בשנים, נמוך = טוב. זה גם המדד שלנו.

נקודת ההשוואה הרלוונטית: Munk et al.

אוכלוסייה קלינית, גיל ממוצע דומה (57.8 מול 57.4). הם: 6.33 עם פי 20 תמונות ואימון מראש. אנחנו: 7.64 מאפס, פער של כ-1.3 שנים. דאטהסטים שונים, ולכן ההשוואה עקיפה.

מבנה העבודה

1. **נתונים**
   פיצול ברמת מטופל ובדיקות תקינות.
2. **מודל ובייסליינים**
   CNN קטן מול מנבא הממוצע ו-ridge regression.
3. **ניסויים מבוקרים**
   12 תצורות, שכל אחת נבדלת מהעוגן שלה בגורם אחד.
4. **ניתוח המודל**
   שגיאה לפי גיל, כיול, saliency, ופער הגיל מול תוויות קליניות.
5. **בקרת איכות ומגבלות**
   תקלות מתודולוגיות שאותרו ותוקנו, והיקף המסקנות.

שלב 1 נתונים ופיצול

הדאטהסט הציבורי ramankamran/retina-age-analysis: 9,857 תמונות רשתית עם גיל המטופל ותוויות קליניות.

פיצול	תפקיד	תמונות	מטופלים
train	אימון	6,902	3,775 (70%)
validation	בחירת מודל וכיול	1,493	809 (15%)
test	הערכה סופית בלבד	1,462	809 (15%)

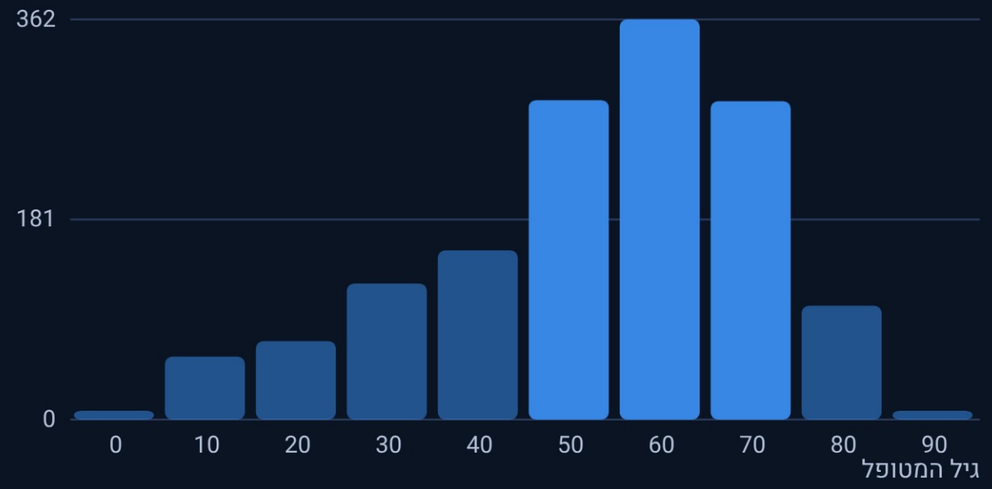
פיצול ברמת מטופל

לרוב המטופלים שתי תמונות, אחת לכל עין (1.83 בממוצע). פיצול לפי תמונה = אותו אדם באימון ובמבחן, ותוצאות מנופחות. `check_patient_leakage` לפני כל סשן: אפס חפיפה.

בדיקת שפיות: RMSE של מנבא הממוצע (18.03) = סטיית התקן של תוויות המבחן.

התפלגות הגיל בסט המבחן

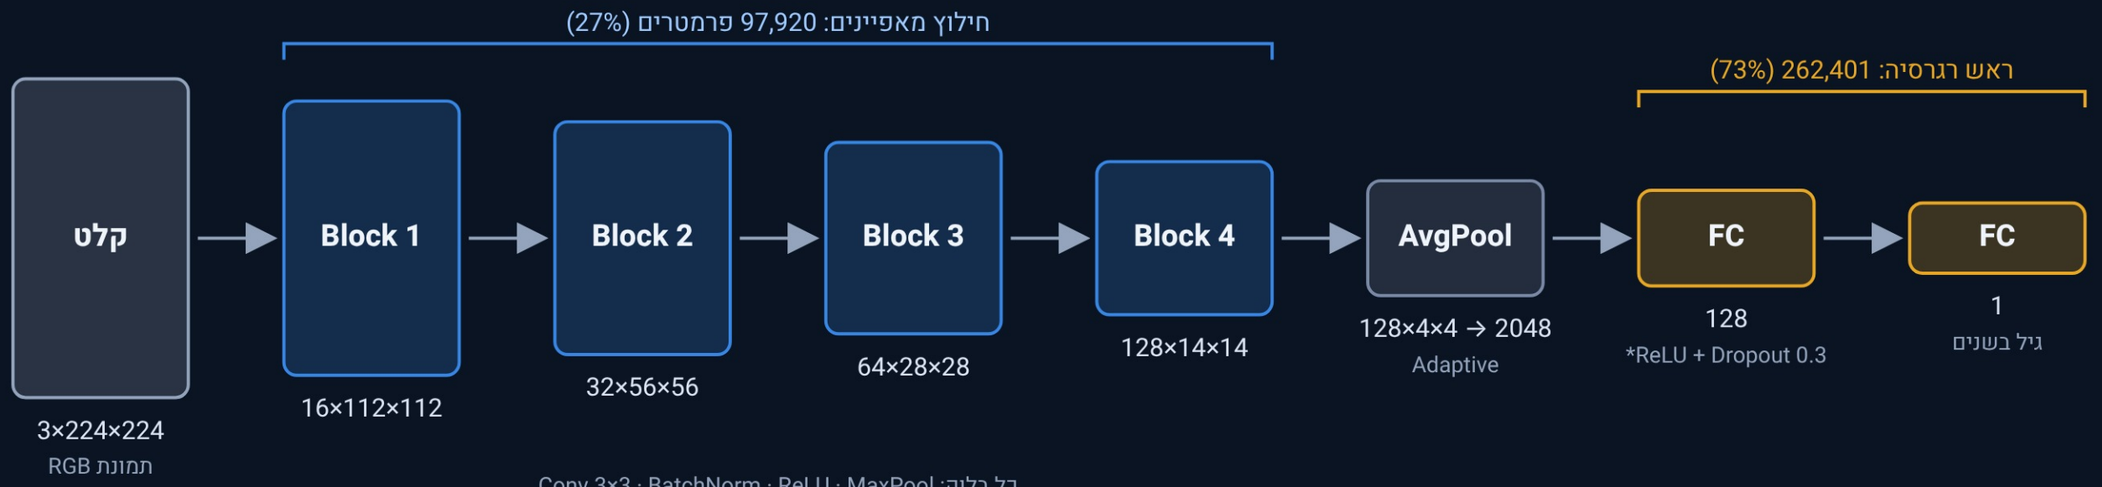
1,462 תמונות · ממוצע 57



הריכוז בגילי **50–79** מסביר את דפוס השגיאה המרכזי (ממצא 2).

שלב 2 המודל: RetinaCNN

מחלקה אחת לכל 12 התצורות. סך הכול **360,321** פרמטרים, ללא אימון מראש.



* Dropout בראש הרשת רק בתצורות שכוללות dropout. רוב הפרמטרים בשכבה המלאה הראשונה (128×2048).

הגדרות אימון

PyTorch, מאפס · 224×224 · batch **32** · Adam, lr **0.001** · MSE loss

epochs **15–40** · **36** הרצות: 12 תצורות, 3 seeds לכל אחת · Kaggle T4, כ-3.5 שעות

צוואר בקבוק בטעינת הנתונים

פענוח תמונות של כ1900×1900- בכל epoch השאיר את ה-GPU ממתין. פתרון: שמירה חד-פעמית בגודל 224.

מ-**600** שנ' ל-**11** שנ' לכל epoch: **האצה פי 55**, 36 מודלים במקום 3.

שלב 2 איך הרשת לומדת

צעד אימון אחד, שחוזר על עצמו אלפי פעמים.



דוגמה: תמונה של בן **51** ← הרשת חוזה **64** ← טעות של 13 שנים ← המשקולות זזות כך שבפעם הבאה החיזוי יתקרב ל־51

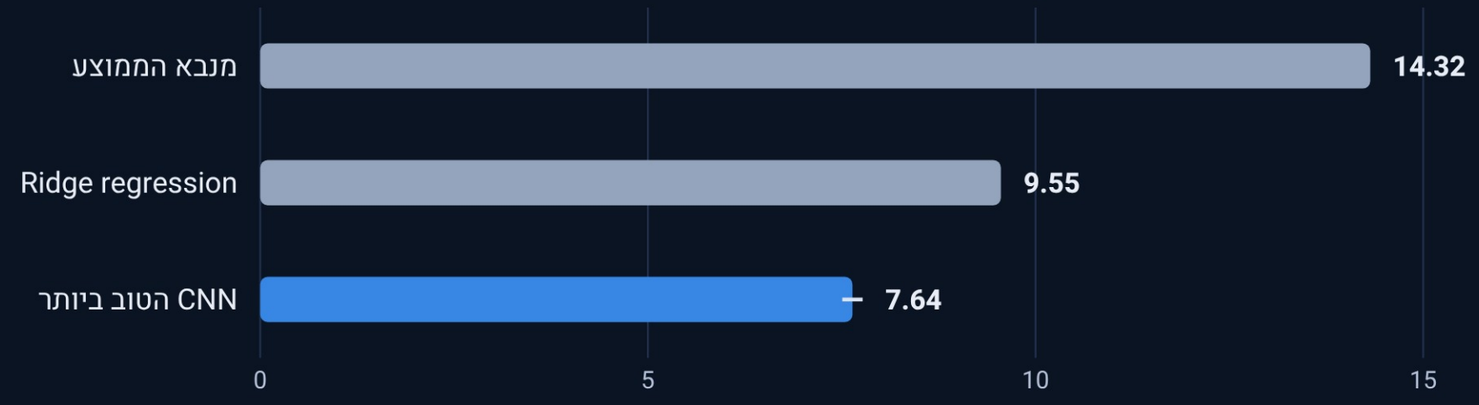
שלב 2 השוואה לבייסליינים

MAE על סט המבחן, בשנים. בייסליין לינארי: ridge regression על מאפיינים ידניים (thumbnail בגווני אפור, ממוצע וסטיית תקן לכל ערוץ, בהירות וניגודיות).

14.32
מנבא הממוצע (57.4)

9.55
Ridge regression

7.64
התצורה הטובה ביותר מבין 12



בייסליינים
CNN: ממוצע 3 seeds, הקו = סטיית תקן

כל 12 התצורות עוברות את שני הבייסליינים. התצורה הטובה ביותר מקטינה את השגיאה בכ-47% לעומת מנבא הממוצע, ובכ-1.9 שנים לעומת ridge.

שלב 3 מטריצת הניסויים

כל תצורה נבדלת מהעוגן שלה בגורם אחד בלבד, כך שכל הפרש ניתן לייחוס לגורם הזה.

תצורה	עוגן	הגורם שמשתנה
מבייסליין לרשת		
cnn_plain	ridge	CNN במקום מודל לינארי
רגולריזציה: כל בלם לבד, ואז שלושתם יחד		
cnn_dropout	cnn_plain	dropout 0.3 בראש הרשת
cnn_wd	cnn_plain	1e-4 weight decay
cnn_es	cnn_plain	early stopping, patience 5
cnn_all	cnn_plain	שלושת הרגולריזטורים יחד
נתונים		
cnn_aug	cnn_all	אוגמנטציה: סיבוב עד 10°, היפוך אופקי, שינוי בהירות
cnn_aug_long	cnn_aug	תקציב epochs: מ-20 ל-40
ארכיטקטורה		
arch_7x7	cnn_all	פילטרים 7×7 בשלושה בלוקים, מספר פרמטרים מותאם
arch_valid	cnn_all	valid padding במקום same
arch_drop_early	cnn_all	Dropout2d בבלוקי הקונבולוציה במקום בראש הרשת
פונקציית loss		
loss_l1	cnn_all	L1 loss
loss_huber	cnn_all	Huber loss, δ = 5 שנים

כל הרשתות באותו גודל

כדי שאף תצורה לא תנצח רק כי היא גדולה יותר. הרשת עם פילטרים 7×7 יצאה בהתחלה כמעט פי 2 גדולה, אז צמצמנו בה ערוצים עד שהגודל השתווה (הפרש של 0.25%). וכשמשנים padding, שכבת AdaptiveAvgPool שומרת על גודל זהה בדיוק.

בקרת אקראיות

seed לפני בניית המודל, DataLoader מקובע. 3 seeds לכל תצורה: ממוצע ± סטיית תקן.

איזו גרסה של הרשת בודקים בסוף

בלי early stopping: הרשת מה-epoch האחרון. עם early stopping: הרשת מה-epoch שהיה הכי טוב על סט האימות.

שלב 3 תוצאות כל התצורות

MAE על סט המבחן, ממוצע של 3 seeds. הקו הקטן: סטיית התקן בין ה-seeds.



רף הרעש

הרצה בודדת יכולה לזוז ביותר משנה: אותה תצורה ואותו seed, שנבדלו רק בתקרת ה-epochs, הגיעו ל-7.62 ול-8.87 (אי-דטרמיניזם של cuDNN). **בממוצע של 3 seeds** לא מפרשים הבדלים מתחת לכחצי שנה.

מה כן אפשר לומר

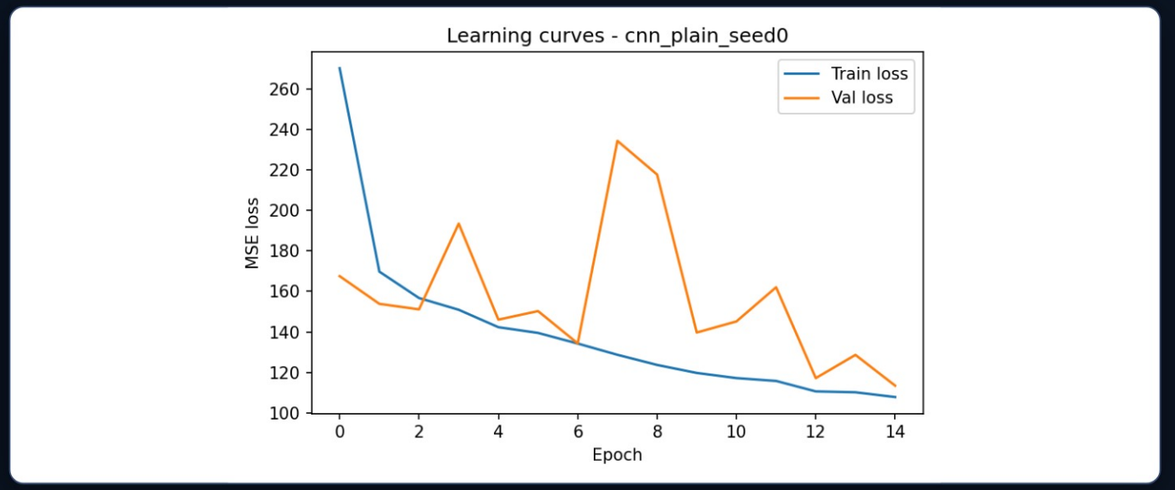
כל התצורות שבתוך הפס המוצלל שקולות לטובה ביותר. כל CNN עובר את שני הבייסליינים, ושלוש החלשות ביותר כוללות dropout.

שלב 3 תהליך האימון

עקומות loss (MSE, בשנים²) של seed 0, לאימון ולסט האימות.

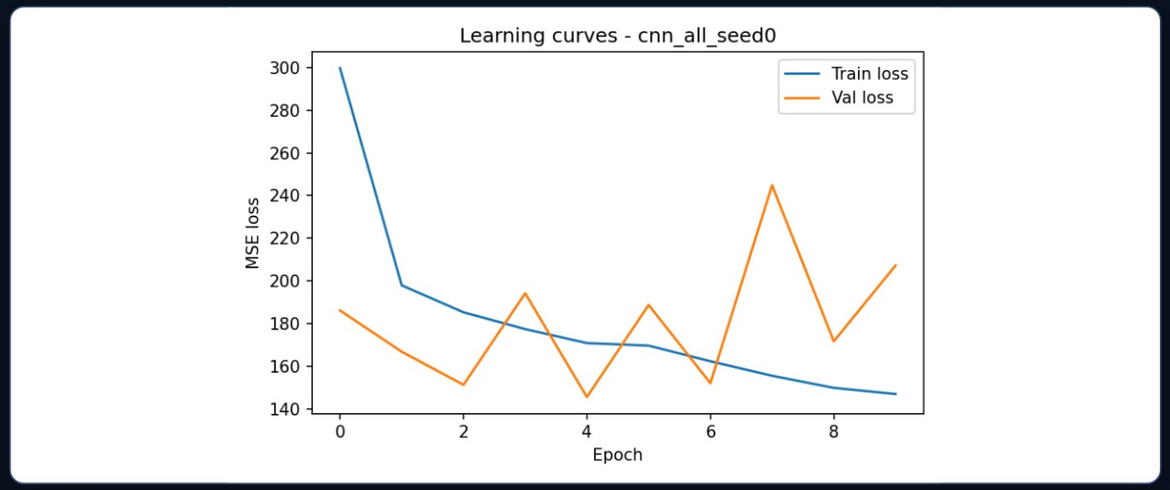
cnn_plain: ללא רגולריזציה

15 epochs מלאים, נבחרות המשקולות האחרונות



cnn_all: dropout + weight decay + early stopping

הטוב ביותר ב-epoch 5, patience 5, עצירה אחרי 10 (הציר מתחיל מ-0)



אין אוברפיטינג קלאסי

ה-train loss יורד בעקביות, וה-validation לא מטפס באופן עקבי. עם הבלמים ה-train loss נשאר גבוה יותר (147 מול 108).

ה-validation רועש מאוד

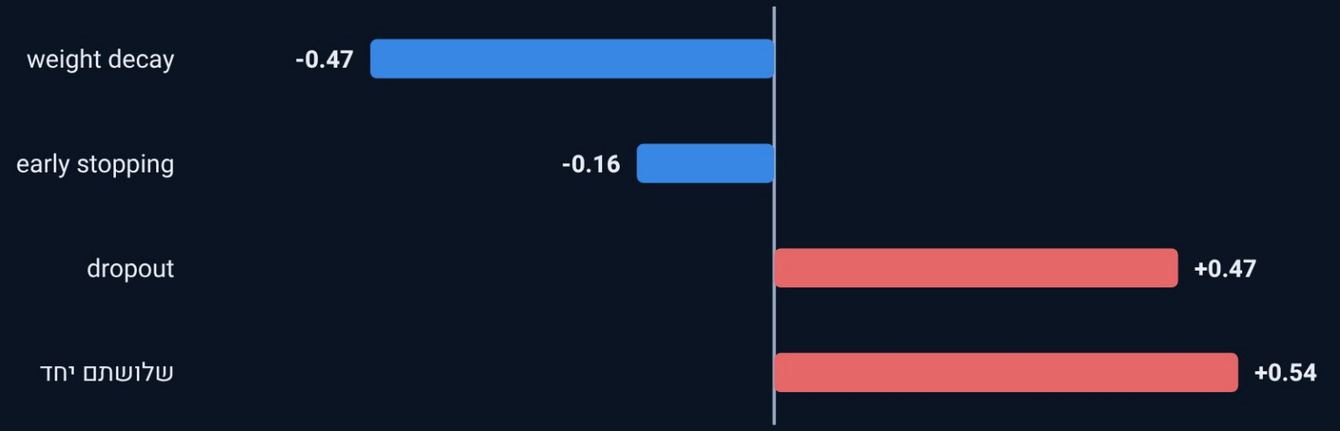
קפיצות חדות בין epochs סמוכים. זה אחד המקורות לשונות בין seeds.

early stopping על עקומה רועשת

עוצר מוקדם, לפני שהמודל סיים ללמוד. קשור ישירות לממצא 1.

ממצא 1 רגולריזציה אינה מצטברת

שינוי ב-MAE מול cnn_plain (8.13). **שמאלה מהקו = שיפור.**



שלושתם יחד גרועים מכל אחד לבד

weight decay נותן את השיפור הגדול ביותר (0.47), אבל זה על גבול רף הרעש: רמז, לא הוכחה. שלושתם יחד: 8.67 בפועל מול 7.97 בחישוב אדיטיבי. עם 360 אלף פרמטרים ו-6,902 תמונות, צירוף רגולריזטורים לא משתלם.

cnn_all נעצר אחרי 10–14 epochs, לפני תקרת ה-15 של cnn_plain.

Bias–variance tradeoff

סטיית התקן בין ה-seeds יורדת מ-0.49 (cnn_plain) ל-0.085 (cnn_all), בזמן שה-MAE עולה. המודל יציב יותר ומדויק פחות.

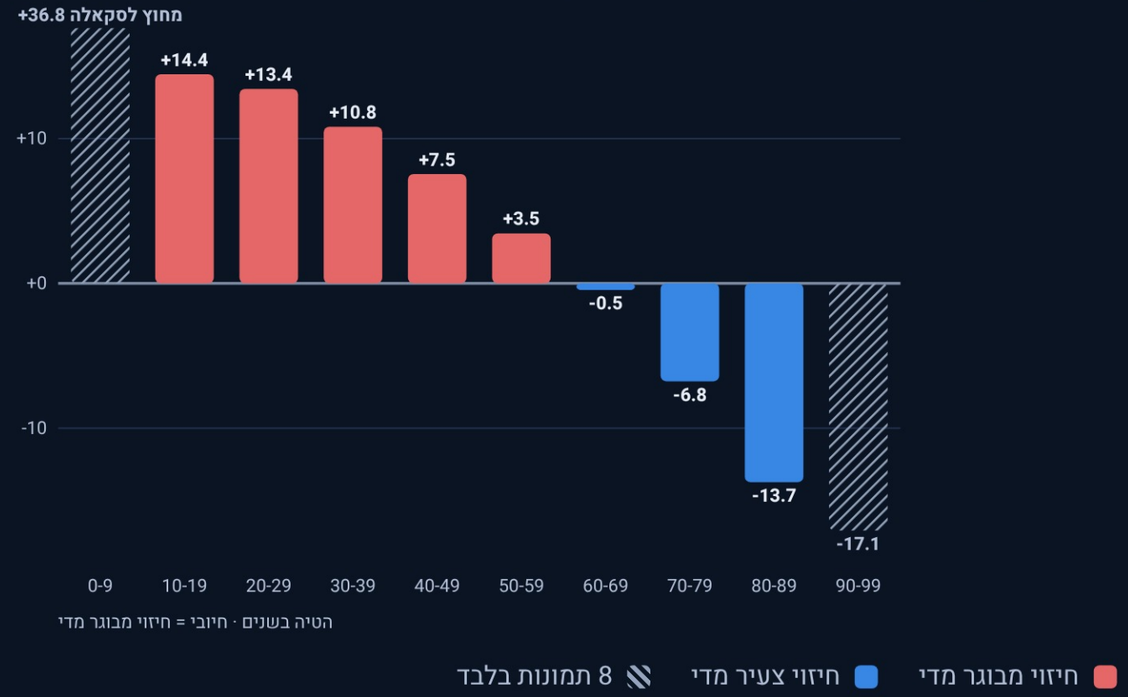
אישור מהכיוון ההפוך: מול cnn_all, חמישה מתוך שישה שינויים משפרים את התוצאה (שיפור ב-MAE, בשנים):

- אוגמנטציה **1.03**
- Huber **0.95**
- valid padding **0.78**
- 7×7 **0.65**
- L1 **0.56**
- Dropout2d בקונבולוציה: החמרה של **0.38**

ממצא 2 השגיאה תלויה בגיל

cnn_all, seed 0 (MAE 8.74), לפי קבוצות גיל. קבוצות 0–9 ו90–99- כוללות 8 תמונות כל אחת ואינן מפורשות.

הטיה לפי קבוצת גיל (חיובי = חיזוי מבוגר מדי)



MAE לפי קבוצת גיל



Regression to the mean

גילי 10–19: מבוגר ב-14.5 בממוצע. גילי 80–89: צעיר ב-13.7. ההטיה חוצה את האפס ב60–69-, ליד ממוצע האימון (57.4). MAE מינימלי ב50–59- (6.04). MSE על התפלגות לא מאוזנת מושך למרכז, ולכן MAE כולל אחד לא מספיק.

ממצא 3 דחיסת החיזויים וכיול

על סט האימות: pred = 0.569 × true + c. החיזויים פורשים 57% מטווח הגילאים. שני תיקונים לינאריים חושבו על סט האימות והופעלו על סט המבחן.

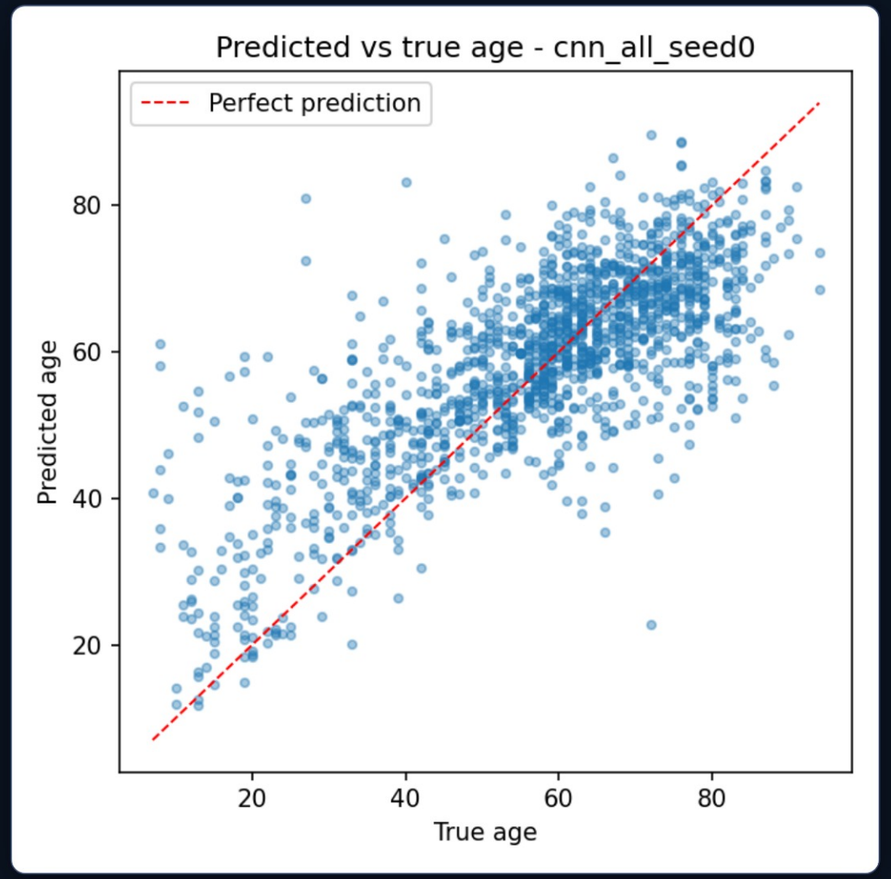
גרסה	MAE	מתאם פער–גיל
חיזוי גולמי ללא תיקון	8.74	-0.677
תיקון A קו ישר שממזער את השגיאה	8.75	-0.704
תיקון B מתיחת החיזויים עד שההטיה לפי גיל נעלמת	11.51	-0.012
Isotonic עקומה גמישה במקום קו ישר, לבדיקה	8.63	-0.682

תיקון A כמעט אינו משנה

שיפוע 0.967, כמעט זהות: החיזויים הגולמיים כבר אופטימליים תחת MSE. הדחיסה צפויה, לא תקלה.

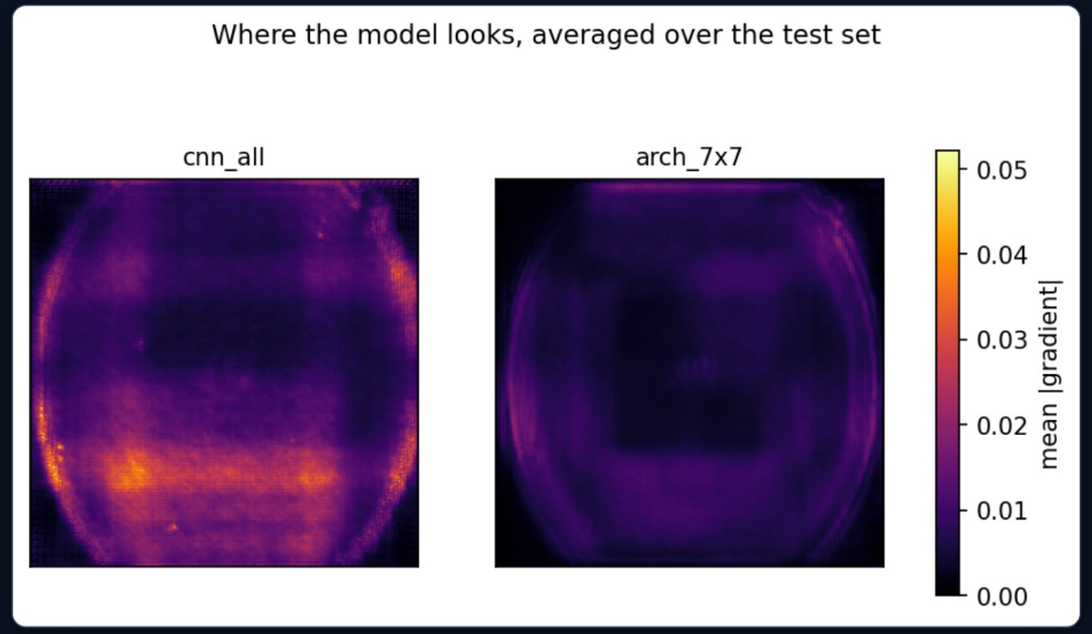
תיקון B מבטל את ההטיה במחיר 2.8 שנים

התלות בגיל נעלמת, אבל ה-MAE עולה ב-32%. Isotonic משפר רק ב-0.11: אין מבנה לא-לינארי. שימוש: גולמי לדיוק, תיקון B לניתוח פער הגיל.



ממצא 4 Gradient saliency

נגזרת הגיל החזוי לפי פיקסלי הקלט, ממוצע על 256 תמונות מבחן. השוואה בין cnn_all (3×3) ל-arch_7x7.



משמאל cnn_all (3×3), מימין arch_7x7.

מדד	3×3 cnn_all	arch_7x7
ריכוז הקשב איזה חלק מההשפעה נמצא ב-10% הפיקסלים החשובים ביותר. גבוה = קשב חד יותר	0.218	0.187
מרכז מול שוליים פי כמה ההשפעה במרכז התמונה גדולה מזו שבשוליים	1.32	**2.24**
חפיפה לכלי דם (בקירוב) מתאם בין מפת הקשב לאזורים עם קווים חדים. 0 = אין קשר, 1 = חפיפה מלאה	0.158	0.128

השוואה בין המודלים

מתאם בין המפות הממוצעות: **0.411**. אזורים דומים, אך לא אותה פונקציה. arch_7x7 ממוקד יותר במרכז ופחות חד.

הסתייגות: הטבעת החיצונית היא ברובה רקע שחור, ו-arch_7x7 שונה גם בעומק (3 בלוקים במקום 4).

ממצא כלי הדם של Poplin לא שוחזר

אצל Poplin et al. כלי דם הודגשו ב-95% מ-100 מפות. אצלנו המתאם עם ניגודיות מקומית, פרוקסי גס לכלי דם, הוא 0.13–0.16. עם פרוקסי כזה ומודל קטן אין בסיס לטענה לאף כיוון.

ממצא 5 האם מחלה קשורה לעין שנראית מבוגרת?

השאלה

האם אצל מטופלים עם ממצא רפואי העין נראית מבוגרת יותר מאשר אצל מטופלים בלעדיו?

הציפייה

כן. בספרות, עין שנראית מבוגרת מהגיל נקשרה לסיכון רפואי.

מה מצאנו

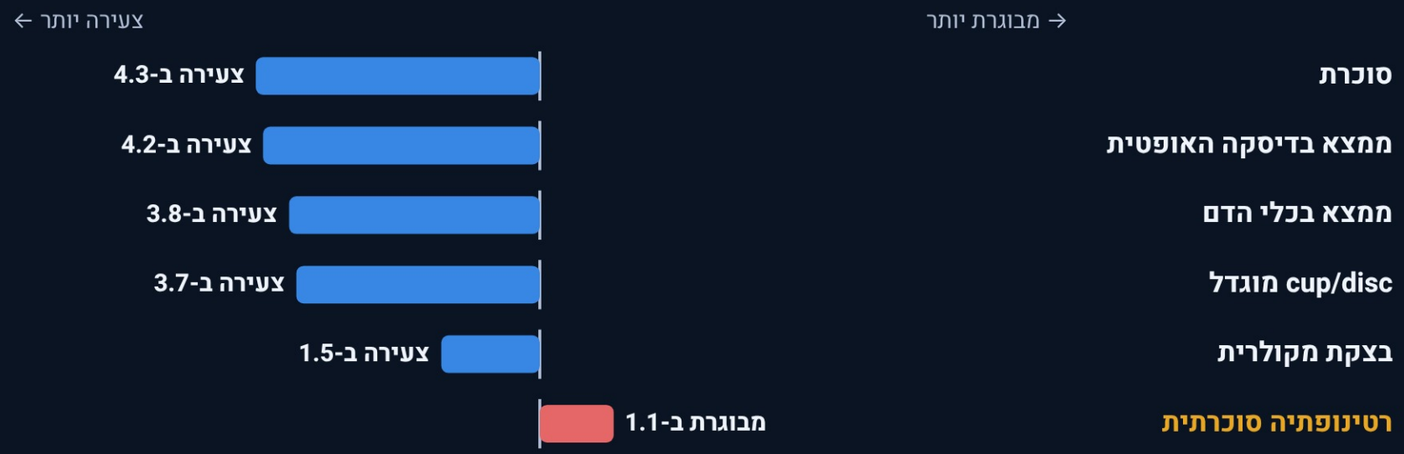
ההפך. בחמישה ממצאים החולים נראים צעירים יותר, ובארבעה מהם **בכ-4 שנים**. רק ברטינופתיה סוכרתית הכיוון הצפוי.

ההסבר הסביר

אופן איסוף הנתונים (מרפאה, תוכנית סקירה, מצלמה), לא ביולוגיה. גודל האפקט קטן: Cohen's d ≈ 0.25–0.29, כלומר כ-4 שנים מול פיזור של כ-15, ולכן תצפית בלבד.

איך נראית העין של מטופלים עם הממצא, לעומת מטופלים בלעדיו

הפרש בשנים. מנוטרלת השפעת הגיל (תיקון B).



בצקת מקולרית: 49 מטופלים בלבד ו-d = 0.10, ולכן לא נספרת עם הארבעה.

שלב 5 בדיקת העבודה: תקלות שמצאנו

תקלות שקטות: הקוד רץ בלי שגיאה, אבל המסקנה הייתה שגויה. שלוש החשובות:

התקלה	איך גילינו	מה היה משתבש במסקנה
הניתוח הרפואי הפך את הסימן	הוספנו פער מזויף של 3 שנים, והקוד החזיר 1.3 שנים בכיוון ההפוך	כל הממצאים הרפואיים היו מדווחים הפוך
הרשת עם פילטרים 7×7 הייתה גדולה פי 2	ספרנו את הפרמטרים בכל רשת	היא הייתה מנצחת כי היא גדולה, לא בגלל גודל הפילטר
כל תצורה התחילה מאתחול אקראי אחר	שתי הרצות שאמורות להיות זהות יצאו שונות	חלק מכל הבדל בין תצורות היה מזל

היקף המסקנות ומגבלות

מה מותר להסיק מהתוצאות, ומה מגביל את העבודה.

אין תצורה מנצחת

גם בממוצע של 3 הרצות, התוצאה יכולה לזוז בכחצי שנה רק ממזל. לכן לא מדרגים תצורות שההפרש ביניהן קטן מזה.

הנטייה לאמצע היא לא תקלה

המודל אומן למזער MSE, ולכן כשהוא לא בטוח הוא מהמר על גיל קרוב לממוצע. ניסינו לבטל את זה, והשגיאה הממוצעת (MAE) גדלה ב-2.8 שנים.

הממצאים הרפואיים הם תצפית בלבד

ראינו שחולים נראים צעירים יותר, אבל ייתכן שזה נובע מאופן איסוף הנתונים ולא מהמחלה. לכן לא טוענים שהמחלה גורמת לזה, ולא בדקנו מובהקות סטטיסטית.

מגבלות העבודה

מקור נתונים אחד: כ-95% מתמונות המבחן צולמו באותה מצלמה, ולא בדקנו את המודל על נתונים ממקור אחר.

3 הרצות בלבד לכל תצורה: בגלל תקציב GPU מוגבל, ולכן הערכת הרעש גסה.

ללא אימון מראש: התחלנו ממשקולות אקראיות, וזה כנראה עלה לנו בדיוק.

כיווני המשך

1. **אימון מראש**
   יפריד בין השפעת כמות הנתונים להשפעת השיטה.

2. **הרצות שחוזרות על עצמן בדיוק**
   לבטל את האקראיות של כרטיס המסך (cuDNN), כך שאותו seed ייתן תמיד אותה תוצאה. אז להריץ שוב את התצורות שבתוך הפס המוצלל ולבדוק אם אחת מהן באמת עדיפה.

3. **טיפול בנטייה למרכז במהלך האימון**
   איזון קבוצות גיל או שקלול גילאים נדירים ב-loss.

4. **לבדוק אם הרשת מסתכלת על כלי הדם**
   לסמן במדויק את כלי הדם בכל תמונה ולהשוות למפות הקשב של הרשת, במקום ההערכה הגסה שלנו. כך נוכל לבדוק את ממצא Poplin.

5. **אימות חיצוני**
   אוכלוסייה ומצלמה אחרות.

סיכום

שגיאה ממוצעת בשנים (MAE), נמוך יותר = טוב יותר

7.64
המודל שלנו
אומן מאפס על 6,902 תמונות

9.55
רגרסיה לינארית
בייסליין

6.33
Munk et al.
פי 20 תמונות + אימון מראש

מסקנות עיקריות

1 · יותר רגולריזציה ≠ יותר טוב
2 · השגיאה תלויה בגיל
3 · הבדלים קטנים = רעש

חלוקת עבודה

שחף: קוד · ניסויים · 36 הרצות · ניתוחים · איתור תקלות
עדי: גישות הפתרון · סקירת ספרות · דוח · מצגת

קוד

github.com/Shahafgino123/retinal-age-cnn

פרויקט קורס, לא לשימוש קליני